

Analyse des tendances immobilières

Analyse, Prédiction de prix et Cartographie

Réalisé et présenté par :

- BENELMAHI Hicham
- EL HAFIDI Mohamed
- EL KARCHAL Soufiane

Sommaire

01 → 

**Introduction &
Objectifs**

02 → 

**Collecte des
Données**

03 → 

**Nettoyage des
Données**

04 → 

**Analyse
Exploratoire**

05 → 

**Modélisation
ML**

06 → 

**Déploiement &
Conclusion**



01 Introduction & Objectifs

Introduction



Le marché immobilier marocain se caractérise par une grande diversité et une forte fragmentation, tant au niveau des types de biens que des zones géographiques, ce qui rend son analyse globale complexe.



Les acheteurs et les locataires rencontrent des difficultés majeures pour comparer objectivement les prix pratiqués, en raison de la dispersion de l'information et de l'absence d'indicateurs de référence fiables.



Il devient alors nécessaire de disposer d'un outil centralisé d'analyse des données immobilières, capable d'exploiter et de croiser les informations issues des plateformes Avito et Mubawab afin d'identifier les tendances réelles du marché.

Objectifs du projet



Automatiser la veille

Scraping des données

Automatiser la récupération des annonces immobilières

Fiabiliser la donnée

Nettoyage & normalisation

Nettoyer, corriger et standardiser les données collectées

Analyse exploratoire

EDA & visualisation

Analyser et visualiser les tendances du marché immobilier

Prédiction des prix

Modèles de Machine Learning

Prédire les prix de l'immobilier à l'aide du Machine Learning

02 Collecte des Données-Scraping

Choix des Sources de Données


Avito.ma



- Volume massif d'annonces
- Données hétérogènes et variées
- Représentation du marché global



Mubawab.ma



- Données plus structurées
- Annonces détaillées et fiables
- Segment immobilier premium

Méthodologie de Scraping



Analyse du site

Analyse du site web

- Structure des pages
- Contenu dynamique / statique
- Chargement JavaScript
 - Comportement utilisateur



Plateformes cibles

Sites immobiliers dynamiques

- Plateformes immobilières dynamiques
(HTML & JavaScript)



Selenium

Selenium WebDriver

- Simulation des clics
 - Scroll & pagination
 - Rendu JavaScript
- **Sélection par TEXTE et non par classes CSS (classes instables sur Avito)**



Parsing HTML


BeautifulSoup

- Parsing du DOM
 - Extraction rapide
 - Données structurées
- Après chargement complet de la page



Données brutes

- Prix
- Localisation
- Surface



Défis et éthique du scraping web

Cette phase vise à garantir une collecte responsable des plateformes web ciblées.


- Respect du fichier robots.txt
- Gestion des délais (time.sleep) pour éviter le bannissement IP
- Rotation des User-Agents



03 Nettoyage des Données

Pourquoi nettoyer les données ?

- Présence de valeurs aberrantes
(ex : surface = 0 m²)
- Doublons entre plateformes
- Formats de prix incohérents





Nettoyage des données et logique métier

Traitement des valeurs manquantes :

Problème	Solution appliquée
Valeurs manquantes (salle_de_bain)	Imputation intelligente basée sur le nombre de chambres
Absence du prix	Suppression des lignes concernées
Absence de la ville	Suppression des lignes concernées

Identification automatique du type de bien immobilier lorsqu'il est manquant.

Règle métier appliquée :

- Si nombre de chambres > 6
- Et présence d'un jardin
→ Bien classé comme Villa
Sinon → Appartement

Prétraitement des données pour le Machine Learning

Qu'est-ce que le preprocessing ?

Le preprocessing regroupe l'ensemble des transformations appliquées aux données afin de les rendre exploitables par les modèles de Machine Learning.

Comment le preprocessing est appliqué ?

- Création de la variable « Prix au m² »
- Encodage des villes par Target Encoding
- Normalisation des surfaces (Scaling)

Pourquoi le preprocessing est nécessaire ?

Les données brutes ne sont pas directement compatibles avec les algorithmes de.

Un bon preprocessing permet :

- d'améliorer la performance des modèles
- de réduire les biais liés aux échelles
- de garantir la stabilité de l'apprentissage

04 ANALYSE EXPLORATOIRE (EDA)

Objectifs de l'Analyse Exploratoire



Comprendre la répartition géographique des annonces




Déetecter les corrélations entre variables



Valider les hypothèses avant le Machine Learning

Dynamique du Marché : Corrélation Prix et Surface



1. Segmentation: Appartements < 200 m² vs Villas dominantes > 600 m².

2. Tendance : Housse constante des prix avec un plafond "luxe" à 40 000 DH.

3. Volume : Offre massive concentrée sous 200 m² et 15 000 DH.

En synthèse : Si la surface dicte la tendance générale du prix, le type de bien reste le facteur déterminant qui verrouille les paliers de valeur, particulièrement sur le segment haut de gamme.

05 Modélisation machine learning

Modélisation Prédictive



Analyse des Corrélations: Identification des variables clés (Surface, Ville, Quartier) ayant le plus d'impact sur le prix final.



Préparation & Robustesse: Définition d'un protocole de test rigoureux (Split Train/Test) pour garantir que le modèle fonctionne sur de nouvelles données.



Optimisation Algorithmique: Comparaison de modèles (Linéaire vs Ensemble) pour atteindre le meilleur compromis entre précision et généralisation.

Stratégie de Modélisation & Choix des Algorithmes



Modèle de base (Baseline)

- Simple et rapide
- Facile à interpréter
- Sert de référence (baseline)



Modèles avancés (Ensemble)

- Agrégation de plusieurs arbres
- Réduction de la Variance
- Robuste au bruit



Objectif de la modélisation

- Éviter le sur-apprentissage
- Maximiser la généralisation



Pipelines

- Encodage des variables
- Normalisation
- Entraînement du modèle




Gradient Boosting / XGBoost

- Apprentissage séquentiel
- Correction progressive des erreurs
- Excellentes performances prédictives



Outils & Méthodes


- Scikit-Learn
- XGBoost
- Pipelines de prétraitement



Avantage :

Réduction des fuites de données et reproductibilité des résultats.

Choix Final : Architecture par Stacking



Concept du Stacking

Fusion des prédictions de plusieurs modèles pour améliorer la précision

Avantage clé

- Erreur résiduelle réduite
- Prédictions plus stables
- Robustesse accrue

Base-Learners

- Random Forest
- XGBoost
- ExtraTrees

Chaque modèle capture des patterns différents du marché immobilier

Meta-Modèle

Régression Ridge

- Agrégation des prédictions
- Régularisation
- Réduction du sur-apprentissage

Protocole d'Entraînement & Robustesse

**Découpage des données
(Vente):**

- | 70 % → Entraînement
- | 15 % → Validation
- | 15 % → Test

→ Évaluer le modèle sur des données
jamais vues

Robustesse du modèle:

Validation croisée

- | 5-Fold Cross-Validation
- | Réduction du hasard
- | Meilleure généralisation

Export production

- | model_location_final_stacking.pkl

Pipeline complet :

- | Encodage
- | Scaling
- | Modèle

→ Modèle directement déployable en production

Résultats du Modèle Stacking (Location)

Résultats quantitatifs:


| R² = 0.73
| MAE = 2 400 DH
| RMSE = 4 844 DH

→ 73 % de la variance du prix expliquée


Interprétation simple

| Erreur moyenne raisonnable
| Stabilité des prédictions
| Bon compromis précision / robustesse

Comparaison modèles



XGBoost seul




Voting



Stacking

Facteurs Déterminants du Prix de location



Surface (m²)

- | Premier levier de valorisation du bien.
- | Plus la surface est grande, plus le prix augmente.
→ Ces variables capturent la même information sous des formes complémentaires.

Quartier

- | Impact spatial majeur.
- | Un même bien peut voir son prix fortement varier selon la localisation.


Type de bien

- | Différenciation claire entre Appartement et Villa.

Observation avancée: Les quartiers haut de gamme agissent comme des multiplicateurs du prix basé sur la surface.

06 Déploiement & Conclusion

Architecture de l'Application Web de Prédiction



Démonstration de l'Outil



Simulation réelle: L'utilisateur peut saisir librement les caractéristiques du bien afin d'obtenir une estimation instantanée.

Conclusion

Une démarche complète en science des données est appliquée, allant de la collecte automatisée des données jusqu'au déploiement de modèles prédictifs fiables. Cette approche repose sur la qualité rigoureuse des données, le choix judicieux des algorithmes et une évaluation méthodique des performances. Ces éléments essentiels garantissent la robustesse, la généralisation et la fiabilité des prédictions obtenues, permettant ainsi d'exploiter efficacement les données pour la prise de décision.



Merci
de votre attention

N'hésitez pas si vous avez des questions.

